

Especialização Lato Sensu em Ciência de Dados e Analytics

# Soluções em Processamento para Big Data

{ APRESENTAÇÃO }

Prof. Jairson Rodrigues jairson.rodrigues@univasf.edu.br

### { apresentação }

Prof. MSc Jairson Rodrigues jairson.rodrigues@univasf.edu.br

Colegiado de Engenharia da Computação Universidade Federal do Vale do São Francisco www.cecomp.univasf.edu.br

- Sistemas Operacionais
- Sistemas Distribuídos
- Criptografia
- Linguagens de Programação



## { agenda }

#### 12-14 de Setembro/2019

- Introdução Big Data
- HPC, Clusters e Grid
- Escalabilidade e Tolerância a Falhas
- Hadoop/MapReduce
- Exercícios Práticos

#### 19-21 de Setembro/2019

- Spark
- Big Data Machine Learning
- Exercícios Práticos
- Avaliação 1
  - Debate de Artigos

# O Que é Big Data?

# Quão BIG é o universo Big Data?

## { big data }



IoT & Big Data, um casamento feito nas Nuvens

### { e outras perguntas importantes... }

Como armazenar massivos volumes de dados?

Quais os problemas e desafios para manipular Big Data com as tecnologias tradicionais?

Como realizar tarefas sofisticadas de análise em volumes inimagináveis e continuamente crescentes de dados?

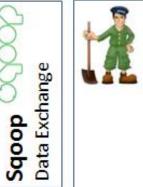
## { ... e sobre tecnologias? }

#### Apache Hadoop Ecosystem



#### Ambari

Provisioning, Managing and Monitoring Hadoop Clusters







Workflow Oozie



Pig

Scripting

Machine Learning Mahout



SQLQuery

Store Columnar Hbase

Hive



Log Collector

Flume

Zookeeper Coordination



YARN Map Reduce v2

Statistics

Distributed Processing Framework

R Connectors



Hadoop Distributed File System

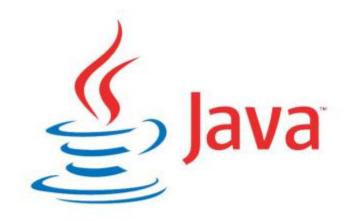


### { ... ecossistema hadoop }

- HDFS -> Hadoop Distributed File System
- YARN -> Yet Another Resource Negotiator
- MapReduce -> Modelo de processamento de dados distribuído
- Spark -> Processamento de dados em memória
- PIG, HIVE-> Serviços de processamento baseado em consultas (SQL-like)
- HBase -> Base de dados NoSQL
- Mahout, Spark MLlib -> Aprendizagem de Máquina para Big Data no Spark
- Apache Drill -> SQL sobre Hadoop
- Zookeeper -> Gerenciamento do cluster
- Oozie -> Agendamento de tarefas
- Flume, Sqoop -> Serviços de ingestão de dados
- Solr & Lucene -> Busca e indexação
- Ambari ->Provisionamento, monitoramento e gerenciamento do cluster

### { ... e sobre linguagens e frameworks? }









# { ... e sobre infraestrutura? }









